

2

Jak AI funguje?

klíčové pojmy

z hlediska:

infrastruktury

dat

trénování

reprezentace informací

porozumění informacím

typu výstupů

klíčové pojmy

z hlediska:

infrastruktury

dat

trénování

reprezentace informací

porozumění informacím

typu výstupů

proč je to důležité?

s čím vlastně pracuji?

jak kvalita dat ovlivňuje výstup | bias

co určuje, co model ví | halucinace

jak vzniká (kvazi)znalost, transparentnost

vztah k žité skutečnosti

pravdivost vs. pravděpodobnost

Infrastruktura

Z čeho se skládá to, čemu říkáme "AI nástroj" – od modelu přes systém až po aplikaci, se kterou uživatel pracuje.

dle infrastruktury

Jádro nástrojů umělé inteligence s **podstatou v matematických výpočtech.**

Kombinace statické architektury (posloupnosti výpočtů) s parametry (váhami) pro výpočty.

Různé modely mají různou architekturu, která definuje jejich základní schopnosti a určuje typ dat, která umí zpracovat.

CNN

(Convolutional Neural Networks)

Zpracovává data pomocí posuvných filtrů, které detekují lokální vzory – detekce obrázků.

Diffusion

Postupně přidává a odstraňuje šum – moderní způsob generování obrázků.

Transformers

Zpracovává celý vstup najednou pomocí attention mechanismu, který zjišťuje vztahy mezi všemi částmi – nejlepší pro dlouhé texty a složitý kontext.

model

systém | aplikace

důsledky

dle infrastruktury

Koncová AI aplikace nebo systém.
Jedná je komplexnější celek, který zahrnuje:

model

systém | aplikace

důsledky

- Samotný model (nebo více modelů)
- Infrastrukturu pro získávání a předzpracování dat
- Uživatelské rozhraní
- Integraci s jinými systémy (API, konektory, MCP)
- Zpětnovazební smyčky pro vylepšování
- Pravidla pro interakce (systémové prompty)
- ...

dle infrastruktury

To, co vidíte v ChatGPT nebo Claude, není jen model – je to celý systém s filtry, pravidly a nástroji.

model

Když se AI chová nečekaně, nemusí to být "hloupost modelu" – může to být nastavení systému, bezpečnostní filtr nebo systémový prompt.

systém | aplikace

důsledky

Proto stejný model v různých aplikacích dává různé výsledky.



Dokážete u své oblíbené AI aplikaci říci,
jaký se jmenuje systém a jak se jmenuje
model?

Data

S jakými daty model pracuje, jak ovlivňují použitá data výstupy.

dle přístupu k datům

data v kontextu AI = naprosto **cokoli**

- ↳ data – fakta bez kontextu
- ↳ informace – data s kontextem a strukturou
- ↳ znalosti – informace s pochopením
- ↳ moudrost – znalosti se zkušeností

problém zploštění

Informace, znalost i moudrost se degraduje na číselně reprezentovaná data.

dle přístupu k datům

transformace pojmů v kontextu AI

data – číselné reprezentace bez kontextu

informace – data s pozičním kontextem a strukturou

~~znalosti – informace s pochopením~~

~~moudrost – znalosti se zkušeností~~



kvaziznalost a kvazimoudrost – simulace znalosti
a moudrosti odvozená statistickými metodami z dat

grokking a emergentní schopnosti

Model nečekaně vyvodí nějakou obecnost nebo získá schopnosti, které nebyly explicitním cílem tréninku.

dle přístupu k datům

rozlišujeme data trénovací a data vstupní

dle přístupu k datům

rozlišujeme data trénovací a data vstupní

- ↳ koncový uživatel neovlivní
- ↳ alfa a omega toho jaké AI poskytuje výsledky
- ↳ data pro učení, validací a testování

dle přístupu k datům

rozlišujeme data trénovací a data vstupní

- ↳ koncový uživatel ovlivní
- ↳ usouvztažněné k trénovacím
- ↳ problematika poskytování dat

dle přístupu k datům

trénovací data

Data používaná pro trénování pochází z velké části z veřejného internetu:

- Texty – Wikipedia, blogy, články, diskuzní fóra
- Obrázky – Google Images, Flickr, sociální sítě
- Video – YouTube, Vimeo

Ale také z kurátorovaných databází:

- otevřené vědecké databáze (výzkumy, články, datasety)
- institucionální databáze
- opensource projekty
- ověřené dedikované korpusy
- digitalizované knihy

dle přístupu k datům

trénovací data

Problémy:

- ❗ autorsko-právní
- ❗ časový, geografický, názorový a mocenský bias
- ❗ AI crawling bots
- ❗ bez specifické domény
- ❗ bezpečnost X napadnutelnost
- ❗ organická x syntetická data

dle přístupu k datům

trénovací data

garbage in – garbage out → důležitost kvalitních dat

dle přístupu k datům

trénovací data

"ODKUD DATA POCHÁZEJÍ?"

Jaké konkrétní zdroje byly použity?

Byly data získána legálně a eticky?

Kdo dal souhlas k jejich použití?

Je seznam zdrojů veřejně dostupný?

"JSOU DATA REPREZENTATIVNÍ?"

Pokrývají všechny relevantní skupiny?

Nejsou geograficky omezená?

Jaké demografické skupiny chybí?

"JSOU DATA AKTUÁLNÍ?"

Z jakého období data pocházejí?

Jak často se model přetrénuje?

Reflektují data současný stav světa?

"JAKÁ ZKRESLENÍ DATA OBSAHUJÍ?"

Jsou data kulturně vyvážená?


Diskriminují určité skupiny?

Obsahují historické předsudky?

Vygeneruj náramkové hodinky, které budou ukazovat půl šesté.




zdroj: Canva AI (2025)



zdroj: Google (2025)

Vygeneruj náramkové hodinky, které budou ukazovat půl šesté.



Zdroj: Claude (2026)



Zdroj: Gemini (2026)



Zdroj: MS Copilot (2026)

dle přístupu k datům

uživatelská vstupní data

Data vkládaná koncovým uživatelem do systému.

- ↳ osobní údaje
- ↳ vstupy – prompty a nahrané dokumenty
 - ↳ uložení
 - ↳ trénování

Nemusí, ale mohou být použita k trénování modelu → čtěte licenční podmínky!

Data drift: vstupní data v provozu se postupně liší od dat, na kterých byl model původně natrénován, což vede ke snížení jeho výkonnosti.

Účení | trénování

Jak model získává své "znalosti" – jaké jsou způsoby učení a kdy do procesu zasahuje člověk.

dle přístupu k učení

Je důležité uvědomit si, že modely se chovají jinak při trénování a jinak při používání koncovým uživatelem.

Složka	Trénování	Používání
Cíl	zlepšit model	odpovědět uživateli
Kdo provádí	vývojář / firma	uživatel
Architektura	fixní	fixní
Parametry (váhy)	měnící se na základě trénování	fixní
Data	trénovací dataset	uživatelský vstup - prompty, kontext,
Inference	ano – model hádá, pak se učí z chyby	ano – model odvozuje z toho, co se naučil

dle přístupu k učení

Typů přístupů k učení je vícero, nicméně následující jsou základní.

Přístup	Jak to funguje	Data označená?	Zásah člověka
Unsupervised	Model hledá vzorce v datech sám – shlukuje podobné, hledá struktury	ne	jen příprava dat
Supervised	Model dostane vstupy + správné odpovědi, učí se je napodobit	ano – člověk předem označil	anotace před trénováním
Reinforcement Learning	Model zkouší akce, dostává odměnu/trest, optimalizuje strategii	ne – jen signál odměny	návrh odměňovací funkce
RL by human feedback	Jako RL, ale odměnu určují lidé (hodnotí výstupy modelu)	ne – lidé hodnotí průběžně	aktivní zapojení během trénování

Příklad procesu u LLM: Pre-training (unsupervised) → (Supervised) fine-tuning → RLHF

Reprezentace informací

V jaké podobě jsou informace a znalosti v modelu uloženy – jasně definované symboly vs. natrénovaná číselná reprezentace.

dle přístupu k reprezentaci informací

symbolický

Symbolický přístup pracuje s **explicitními symboly a pravidly**, podobně jako když řešíme matematickou rovnici nebo logickou úlohu; jednoduše – ručně kódovaná znalost:

subsymbolický

- Používá symboly (slova, čísla, logické výrazy) a pravidla pro jejich manipulaci.
- Funguje na principu logického odvozování – "když A, pak B".
- Je transparentní - můžeme sledovat, jak došla k závěrům.
- Znalost je fixována na vnější vstup – jasně dané pravidla a propozice.

příklad

důsledky

Příklady využití přístupu: GOFAL, expertní systémy (MYCIN), tradiční šachové programy

dle přístupu k reprezentaci informací

symbolický

Subsymbolický přístup nepoužívá explicitní symboly, ale pracuje s **číselnou reprezentací**. Znalost není explicitně definovaná člověkem, ale vyjádřená číselnými parametry, které vznikly při trénování.

subsymbolický

příklad

- Využívá propojené numerické hodnoty místo logických pravidel
- Učí se statistickými metodami na velkém množství dat
- Je méně vysvětlitelný, funguje jako "černá skříňka"
- Znalost je fixována v naučených číselných parametrech (vahách)

důsledky

Příklady využití přístupu: to co v současné době pojmenováváme jako AI

dle přístupu k reprezentaci informací

symbolický

Zadání: filtr pro rozeznání spamu

Symbolická AI:

IF email obsahuje "viagra" THEN spam = true

IF odesílatel není v kontaktech THEN spam = true

subsymbolický

příklad

Subsymbolická AI:

- Zpracuje tisíce emailů označených jako "spam/ne-spam"
- Inicializuj náhodné váhy (numerické parametry)
- Opakuje:
 - Projde všechny emaily
 - Porovná svou predikci s předem označeným
 - Uprav váhy směrem k menší chybě
- Dokud se nezlepšuješ (parametricky nastaveno)

důsledky

dle přístupu k reprezentaci informací

symbolický

Znalosti v AI nejsou uložené jako fakta, která můžete přechýst nebo opravit. Jsou rozpuštěné v miliardách čísel.

subsymbolická

Proto když AI řekne nepravdu, nemůžete "opravit ten jeden fakt" – můžete to jen obejít (dát správnou informaci do promptu) nebo ověřit jinde.

příklad

důsledky

A proto ani tvůrci modelu nevědí přesně, co model "ví".

Porozumění informacím

Pochopení toho, že model nerozumí tomu, co říká – pracuje se vzorci, ne s významy, i když výstup vypadá smysluplně.

dle přístupu k porozumění informacím

syntaktický

Syntaktický přístup využívá **pravděpodobnostní a statistické metody** k usouvztažnění informací. Zaměřuje se na vztahy mezi znaky v systému.

sémantický

- Systém rozpoznává pravidelnosti, relace mezi prvky, formální struktury
- Neví, co prvky znamenají – jen jak se chovají a kombinují

příklady

důsledky

Příklad: LLM vyvozuje na základě trénování, že po "pes je" často následuje "savec", "zvíře", "věrný" – ale neví, co je pes, zvíře, věrný ani savec

dle přístupu k porozumění informacím

syntaktický

Sémantický přístup naopak klade důraz na **reprezentaci a porozumění významu informací**. Zaměřuje se na vztah znaku k realitě.

sémantický

příklady

- Systém by rozuměl, na co se symboly odkazují ve světě
- Znalosti by měl uložené ve znalostním grafu

důsledky

V sémantickém přístupu by model měl uloženo ve znalostním grafu, že "pes → savec, zvíře, štěká, kouše, vrtí ocasem".

dle přístupu k porozumění informacím

syntaktický

Jak by zpracovaly větu "když prší, je mokro":

Syntaktický model:

sémantický

„Přečetl jsem milion zpráv o počasí a slova 'prší' a 'mokro' se v 95 % případů vyskytují spolu. Takže když vidím 'prší', napíšu 'mokro'.“

příklady

důsledky

Sémantický model:

- Fakt 1: Venku PRŠÍ.
- Pravidlo A: PRŠENÍ vždy způsobuje VLHKOST.
- Pravidlo B: VLHKOST definujeme jako stav MOKRO.
- Závěr (vyvození): Protože platí Fakt 1, aktivuje se Pravidlo A (vlhkost). Protože máme vlhkost, aktivuje se Pravidlo B → Výsledek: Je mokro.

dle přístupu k porozumění informacím

syntaktický

Jak by doplnily větu “Paříž je hlavním městem ...”

Syntaktický model:

Francie - ne proto, že by věděl, že existuje Francie a v té, že je město Paříž, a že to město je hlavní; je to proto, že v datech se často vyskytuje spojení slov: Paříž-Francie-hlavní-město.

sémantický

příklady

Sémantický model:

- Identifikuje pojmy: Ve větě rozpozná entity „Paříž“ a „hlavní město“ jako unikátní symboly ve své databázi.
- Najde pevnou vazbu: V grafu znalostí vyhledá spojení:
Paříž – hlavní město → Francie
- Doplní „Paříž“ jako výsledek logického dotazu, nikoliv jako statisticky pravděpodobné slovo.

důsledky

dle přístupu k porozumění informacím

syntaktický

AI nerozumí tomu, co říká – rozpoznává vzorce a generuje pravděpodobná pokračování.

sémantický

Proto může napsat plynulý text o něčem, co neexistuje. Proto sebevědomý tón neznamená správnost.

příklady

důsledky

Když AI tvrdí něco s jistotou, není to proto, že to ví – je to proto, že takto vypadaly texty, na kterých se učila.



Zeptejte se své oblíbené chatovací AI:

Jak víš, že Paříž je hlavním městem Francie?

Typy výstupů

Proč stejný dotaz může dát různé odpovědi – vztah mezi určitostí a pravděpodobností.

dle přístupu k typu výstupu

deterministický

Deterministický přístup funguje na principu **stejný vstup** → vždy **stejný výstup**.

probabilistická

příklady

důsledky

- Pravidla jsou pevná, inference (odvozování) je logická
- Pokud platí A a B, pak nutně platí C
- Výsledek je buď správně, nebo špatně – žádná "míra jistoty"

dle přístupu k typu výstupu

deterministický

Probabilistický přístup určuje **pravděpodobnostní rozdělení výstupů**.

probabilistická

příklady

- Stejný vstup → může vést k různým výstupům (s různou pravděpodobností)
- Model pracuje s nejistotou, odhaduje, co je nejpravděpodobnější
- Na základě vzorců v datech predikuj, co asi následuje
- Výsledek má vždy přiřazenou "míru důvěry"

důsledky

dle přístupu k typu výstupu

deterministický

Deterministický

KLÍČOVÁ SLOVA → ODPOVĚĎ:

- "heslo" + "reset" → "Pro reset hesla klikněte na odkaz..."
- "zrušit" + "předplatné" → "Pro zrušení volejte 800..."

probabilistická

příklady

Vstup: "Chci resetovat heslo"

Výstup: "Pro reset hesla klikněte na odkaz..." ← vždy totéž

důsledky

Probabilistický

Vstup: Napiš mi něco o kočce.

Pokus 1: "Kočka spí na gauči."

Pokus 2: "Kočka loví myši na zahradě."

Pokus 3: "Kočka mňouká u dveří."

dle přístupu k typu výstupu

deterministický

Stejný dotaz může dát různé odpovědi – a všechny mohou být "správné" z pohledu modelu.

probabilistická

Proto když potřebujete konzistenci, musíte ji vynutit (přesnější prompt, nižší teplota).

příklady

důsledky

A proto když AI řekne něco jednou, neznamená to, že to řekne znovu. Není to databáze faktů – je to generátor pravděpodobných odpovědí.

AI jako komplexní systém

Systém	Reprezentace	Zpracování	Výstup	Příklad
Běžný program	–	–	deterministický	kalkulačka, účetní software
GOFAI / Expertní systém	symbolická	sémantické (člověkem definované)	deterministický	diagnostický systém, šachový engine
Rozhodovací strom	symbolická	syntaktické	deterministický	schvalování úvěrů, triáž
Bayesovská síť	symbolická	sémantické	probabilistický	lékařská diagnostika, risk analýza
Klasifikátor (neuronová síť)	subsymbolická	syntaktické	probabilistický	rozpoznávání obličejů, spam filtr
LLM	subsymbolická	syntaktické	probabilistický	Claude, ChatGPT, Gemini
Neurosymbolická AI	obojí	snaží se o sémantické	různé	výzkumné systémy kombinující učení s logickým usuzováním